

2025 年度卒プロⅡ最終レポート

2026 年 1 月 26 日提出

指導教員：三和 義秀

軽量 LLM を用いた SNS テキストの感情分析
— Zero-shot・LoRA・フルファインチューニングの比較 —

愛知淑徳大学
人間情報学部人間情報学科

23048NKU

鷺津亮

1. 序論

1.1 研究背景

大規模言語モデルは翻訳・要約・質問応答など多様な自然言語処理タスクで高い性能を示しており (Brown et al., 2020), 感情分析においても学習なしの Zero-shot 推論で高精度が報告されている (Zhang, Deng, Liu, Pan, & Bing, 2023)。しかし, フルファインチューニングには多大な計算資源が必要であり, 実用には LoRA のような省メモリ手法の活用が課題となる (Hu et al., 2021)。日本語においても LoRA を用いた研究が進みつつある。王・中町・佐藤 (2023) は日本語 GPT モデル (6.7B) に対してフルファインチューニングと LoRA を比較し, フル FT が 6,666M の学習パラメータと約 483GB の GPU メモリを必要としたのに対し, LoRA はわずか 16M の追加パラメータと 54MB のメモリで済みながら, 含意認識タスクにおける精度が 0.927 から 0.935 へと向上したことを報告している。また, 助田・鈴木・坂地・小寺 (2024) は医療ドメインの日本語 LLM に LoRA を適用し, 専門知識を効率的に組み込める可能性を示している。しかし, これらの研究の多くは感情分析を対象としておらず, 日本語感情分析における LoRA とフルファインチューニングの比較検証は十分に行われていない。

1.2 研究目的

本研究の目的は, SNS 投稿を対象とした感情分析において, Zero shot 推論, LoRA, およびフルファインチューニングの三手法を比較し, 性能と計算コストの観点から LoRA の有効性と特性を明らかにすることである。

1.3 研究方法

本研究では, 日本語における感情分析タスクに対する学習手法の特性を比較検証することを目的とし, SNS 投稿を対象とした日本語感情分析データセットである WRIME Ver.2 を用いてポジティブとネガティブの二種類に再構成し, 文章を二値で分類するタスクとして扱う。WRIME Ver.2 に含まれる感情極性ラベル (-2 ~ +2) を基準とし, ポジティブ (+1, +2) とネガティブ (-1, -2) に分類し, 中立に相当する 0 は分析対象から除外する。さらに学習用・検証用・テスト用にデータを適切に分割を行う。使用するモデルには Google によって公開された最新の軽量モデルである Gemma 3 (270M) を採用する。このモデルは, わずか 2 億 7,000 万パラメータという小規模ながら, 事前学習によって指示追従能力と構造化テキスト処理能力が付与されているほか, タスク固有のファインチューニング用途を前提に設計されている点に特徴がある (Lacombe et al., 2025)。また, Gemma 3 は計算資源の限られた環境でも動作可能な設計がなされており, 性能と計算コストの両面から比較を行う本研究の目的に適していると判断した。比較対象とする学習手法は Zero-shot 推論, LoRA による省メモリファインチューニング, およびフルファインチューニングの三種

類とする。比較にあたっては分類性能に加え、学習パラメータ数、および学習時間を記録し、各手法における性能と計算コストの関係を評価する。

2. 先行研究の検討

2.1 大規模言語モデルにおける感情分析

Brown et al. (2020) は、大規模言語モデルは翻訳・要約・質問応答など多様な自然言語処理タスクで高い性能を示すことを報告している。さらに Zhang, Deng, Liu, Pan, & Bing, (2023)は感情分析においても学習なしの Zero-shot 推論で高精度を示すことを報告している。しかし、これらのモデルはパラメータ数が膨大であり、特定のタスクやドメインに特化させるフルファインチューニングには、莫大な計算コストとメモリが必要となる点が問題となっている。

2.2 LoRA

計算資源の制約を克服する手法として、Hu et al. (2022) は Low-Rank Adaptation (LoRA) を提案した。本手法は、フルファインチューニングのようにすべてのパラメータを更新するのではなく、元のモデルパラメータを固定し、特定の層に対して低ランクの行列を追加して学習を行うものである。これにより、モデル全体のパラメータを更新する場合と比較して、学習パラメータ数を大幅に削減しつつ、同等の精度を維持することが可能となる。

2.3 日本語モデルへの適用

日本語 LLM においても LoRA の有効性は実証され始めている。王・中町・佐藤 (2023) は含意認識タスクにおいて、助田ら (2024) は医療ドメインにおいて、それぞれ LoRA がフルファインチューニングに対して極めて低いメモリ消費で高性能を達成することを報告した。しかし、これらの先行研究は「含意認識」や「専門知識」を問うタスクが中心であり、「感情分析」タスクについては十分な検証がなされていない。

3. 実験結果

3.1 実験条件

3.1.1 実行環境と実装

本実験は、Google Colaboratory (GPU: NVIDIA T4) 上で実施した。実装には Python を使用し、Hugging Face の transformers および peft ライブラリを用いた。なお、ファインチューニングのプログラムに関しては、山田(2023)の実装を参考にし、本研究の目的に合わせてモデルを Gemma 3 (270M)に、変更・調整して使用した。

3.1.2 学習ハイパーパラメータ

比較実験における公平性を保つため、エポック数やバッチサイズ等の基本設定は全手法で統一した。詳細なパラメータ設定を表 1 に示す。

項目	Full Fine-tuning	LoRA
Base Model	Gemma 3 (270M)	Gemma 3 (270M)
Epochs	3	3
Batch Size	32	32
Learning Rate	2.00E-05	2.00E-04
Max Seq Length	512	512
LoRA Rank (r)	-	8
LoRA Alpha	-	32
LoRA Dropout	-	0.1
Trainable Params	268,469,376 (100%)	369,920 (0.14%)

表 1 学習パラメータ設定

3.2 学習効率


3.2.1 計算コストの比較

各手法における学習完了までの所要時間および学習対象パラメータ数を比較行った結果を示す。学習時間については、フルファインチューニングが学習完了までに約 885 秒を要したのに対し、LoRA は約 520 秒で学習を完了し、計算時間を約 40%短縮した。パラメータ数についてはフルファインチューニングでは全パラメータ（約 2.68 億）を更新する必要があるが、LoRA では更新対象を全パラメータの約 0.14%（約 37 万パラメータ）に抑えることができた。


3.2.2 学習曲線

学習プロセス（Epoch 1～3）における損失と検証データに対する精度の推移を図 1 から 4 に示す。LoRA についてはエポックが進むにつれて学習損失（Training Loss）と検証損失（Validation Loss）が共に低下しており、安定した学習が行われた。フルファインチューニングについて、Epoch 3 において、学習データに対する損失は極めて低い値


（0.0297）まで低下したが、検証データに対する損失は逆に上昇（0.5105）する挙動が確認された。



☒ 1 LoRA Loss Curve



☒ 2 Full FT Loss Curve



☒ 3 Validation Loss Comparison




図 4 Validation Accuracy Comparison

3.3 最終精度評価

事前学習済みモデルをそのまま用いた Zero-shot 推論の正解率は 58.17%にとどまり，タスク特化の学習を行わない状態では十分な性能が得られないことが確認された。LoRA を用いたモデルは 90.06%の正解率を達成し，本実験において最も高い性能を示した。フルファインチューニングも 88.43%と高い精度を記録したが，LoRA と比較すると約 1.6 ポイント低い結果となった。

手法	正解数 / テスト総数	Accuracy (正解率)
Zero-shot	1036 / 1781	58.17%
Full Fine-tuning	1575 / 1781	88.43%
LoRA	1604 / 1781	90.06%

表 2 各手法の正答率

4. 考察と今後の課題

4.1 考察

4.1.1 LoRA の有効性

表 2 の実験結果から LoRA は他の手法と比べて最も正答率が高かった。さらにフルファインチューニングと比較し，LoRA は約 520 秒で学習を完了し，計算時間を約 40%短縮した。また，学習パラメータ数も 0.14%まで削減することができた。このことは王ら(2023)の先行研究と同様の結果となった。このことから SNS テキストにおける感情分析においても LoRA の有効性が示された。

4.1.2 フルファインチューニングにおける過学習の兆候

フルファインチューニングの学習について図 2 からエポックが進むにつれて、トレーニング用のデータに対して損失が下がっていくことがわかる。しかし、検証用データに対してはエポックが 1 から 2 の間は少しだけ損失が下がったものの、エポック 3 の時点では急上昇している。このことから、トレーニングデータだけにモデルが過度に適合してしまう過学習に陥っていることがわかる。

4.1.3 Gemma 3 の適性

Gemma 3 はわずか 2.7 億パラメータと軽量のモデルである。このモデルを適切にファインチューニングすることで 90%の精度が出たことについて考察をする。(Lacombe et al., 2025)にあるように、Gemma 3 は特定のドメインや言語に合わせてさらにファインチューニングできる強力なベースモデルとなっている。また指示チューニングもされているため、一般的な指示に即座に従える強力なモデルとなっている。このようにファインチューニングをする前のベースモデルのアーキテクチャやチューニングのおかげで今回のファインチューニングで精度を向上させることができたと考える。

4.2 今後の課題と展望

4.2.1 多値分類への拡張

今回は SNS テキストをネガティブ・ポジティブの二値に分類する比較的単純なタスクを与えた。使用した WRIME データセットが持つ多段階の感情極性を活用した多値分類へとタスクを難化させた場合において、LoRA がどのような精度を出すのかを検証する必要がある。

4.2.2 ハイパーパラメータの最適化

王ら(2023)では LoRA ハイパーパラメータの探索が行われている。今回の実験では LoRA のランク ($r=8$) や Alpha (32), Epoch を固定して比較を行ったが、これらの値を変化させたときどのように精度が変化し、計算コストはどうなるのかなどを検証する必要がある。

文献リスト

- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., ... Amodei, D. (2020). Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems*, 33, 1877-1901.
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., ... Chen, W. (2022). LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations*.
- 王 昊・中町 礼文・佐藤 敏紀 (2023). 日本語の大規模な基盤モデル に対する LoRA チュ

ーニング 言語処理学会第 29 回年次大会発表論 文集, 2222-2226.

Lacombe, O., Kenealy, K., Black, K., Kumar, R., Visin, F., & Zhang, J. “Gemma 3 270M の概要: 超高効率 AI のためのコンパクトモデル”. Google for Developers. 2025 年 8 月 14 日 . <https://developers.googleblog.com/ja/introducing-gemma-3-270m>, (2025 年 10 月 20 日)

助田 一晟・鈴木 雅弘・坂地 泰紀・小寺 聡 (2024). JMedLoRA : Instruction-tuning による日本語大規模モデルの医療ドメイン適 用 言語処理学会第 30 回年次大会発表論文集, 2548-2553.

Zhang, W., Deng, Y., Liu, B., Pan, S. J., & Bing, L. (2024). Sentiment Analysis in the Era of Large Language Models : A Reality Check. FindingComputational Linguistics: NAACL 2024, 3881-3906.

山田育矢(2023). 大規模言語モデル入門, 技術評論社