

2026 年度卒業論文

2026 年 7 月 30 日提出

指導教員：三和 義秀

WRIME Ver.2 を用いた LLM による SNS 投稿の感情分析
— ゼロショット・LoRA・フルファインチューニングの比較 —

愛知淑徳大学
人間情報学部人間情報学科

23048NKU

鷺津 亮

目 次

1. 序論
 - 1.1 研究背景
 - 1.2 研究目的
 - 1.3 研究方法
2. 関連研究
 - 2.1 感情分析
 - 2.2 WRIME および WRIMEVer.2
 - 2.3 大規模言語モデルを用いた感情分析
 - 2.4 LoRA によるファインチューニング
3. 実験方法
 - 3.1 タスク設定
 - 3.2 使用データセット
 - 3.3 使用モデル
 - 3.4 比較手法
 - 3.5 評価指標
 - 3.6 実験環境
4. 結果
 - 4.1 分類性能の比較
 - 4.2 学習コストの比較
5. 考察
 - 5.1 各手法の比較
 - 5.2 分類性能と学習コストのトレードオフ
6. 結論
 - 6.1 本研究のまとめ
 - 6.2 今後の課題

1. 序論

1.1 研究背景

大規模言語モデル (Large Language Model: LLM) は、翻訳・要約・質問応答など多様な自然言語処理タスクで高い性能を示している (Brown et al., 2020)。また、感情分析においても LLM の有効性が検証されているが、その性能はタスクの複雑さやタスク設定に依存することが報告されている (Zhang et al., 2024)。

LLM を特定のタスクへ適応させるため、モデル全体のパラメータを更新するフルファインチューニングが広く用いられている。しかし、フルファインチューニングでは全パラメータを学習対象とするため、多大な計算資源が必要となる。この課題を解決する手法として、少数の追加パラメータのみを学習する LoRA (Low-Rank Adaptation) が提案されている (Hu et al., 2022)。

日本語においても LoRA を用いた研究が進みつつある。王・中町・佐藤 (2023) は、日本語 GPT モデル (6.7B) に対してフルファインチューニングと LoRA を比較し、フルファインチューニングが 6,666M の学習パラメータと約 483GB の GPU メモリを必要としたのに対し、LoRA は 16M の追加パラメータと 54MB のメモリで済みながら、含意関係認識タスクにおいて同等以上の性能を示したことを報告している。また、助田・鈴木・坂地・小寺 (2024) は、医療ドメインの日本語 LLM に LoRA を適用し、専門知識を効率的に組み込める可能性を示している。

しかし、これらの研究の多くは感情分析を対象としておらず、日本語感情分析におけるゼロショット、LoRA、およびフルファインチューニングの比較検証は十分に行われていない。

1.2 研究目的

本研究の目的は、SNS 投稿を対象とした日本語感情分析において、大規模言語モデルを用いた複数の手法を比較し、分類性能および学習コストの観点から各手法の特徴を明らかにすることである。具体的には、WRIME Ver.2 に含まれる日本語 SNS 投稿を対象とし、書き手本人による感情極性ラベルを用いた 5 クラス分類タスクを設定する。

本研究では、学習を行わずプロンプトのみで分類を行うゼロショット、少数の追加パラメータのみを学習する LoRA ファインチューニング、モデル全体を更新するフルファインチューニングの三手法を比較する。これにより、日本語 SNS 投稿の感情極性分類において、LoRA がフルファインチューニングと比較してどの程度の分類性能を示し、学習コストをどの程度削減できるかを検討する。

1.3 研究方法

本研究では、日本語 SNS 投稿に対して感情極性ラベルが付与されたデータセットである WRIME Ver.2 (Suzuki et al., 2022) を用いる。WRIME Ver.2 は、書き手本人による

主観的な感情極性ラベルと、読み手による客観的な感情極性ラベルが付与されたデータセットであり、WRIME (Kajiwara et al., 2021) を拡張したものである。本研究では、このうち書き手本人による主観的な感情極性ラベルを使用する。データセットは WRIME Ver.2 の公式分割に従い、学習用 30,000 件、検証用 2,500 件、テスト用 2,500 件を使用する。なお、各分割間で書き手は重複しない。

書き手本人による感情極性ラベル (-2~+2) を用いて感情極性分類を行うタスクを設定する。具体的には、「-2 (強いネガティブ)」「-1 (ネガティブ)」「0 (中立)」「+1 (ポジティブ)」「+2 (強いポジティブ)」の 5 段階からなる感情極性を予測対象とする。本研究では、これらのラベルを予測する 5 クラス分類タスクとして扱う。

使用するモデルには、Google によって公開された Gemma 3 系列の軽量言語モデルである Gemma 3 270M を採用する。このモデルは、2 億 7,000 万パラメータという小規模ながら、事前学習によって指示追従能力と構造化テキスト処理能力が付与されているほか、タスク固有のファインチューニング用途を前提に設計されている点に特徴がある

(Lacombe et al., 2025)。また、Gemma 3 は計算資源の限られた環境でも動作可能な設計がなされており、分類性能と学習コストの両面から比較を行う本研究の目的に適していると判断した。

比較対象とする手法は、プロンプトを用いた学習なしのゼロショット、LoRA によるパラメータ効率の高いファインチューニング、およびフルファインチューニングの三種類とする。ゼロショットでは、モデルに感情極性ラベルを直接出力させる。LoRA およびフルファインチューニングでは、5 クラス分類用の分類ヘッドを用いて各ラベルを予測する。各手法において感情極性分類を行い、分類性能と学習コストを比較する。

評価指標には Quadratic Weighted Kappa (QWK) を主指標として用いる。感情極性ラベルには順序関係が存在するため、QWK は予測ラベルと正解ラベルの距離を考慮した評価が可能であり、本タスクの評価に適している。また、補助指標として Accuracy および Mean Absolute Error (MAE) も算出する。さらに、LoRA とフルファインチューニングについて、学習時間、学習可能パラメータ数、学習時の最大 GPU メモリ使用量を比較し、分類性能と学習コストのトレードオフを評価する。

2. 関連研究

2.1 感情分析

感情分析とは、テキストに表された人の意見、評価、態度、および感情を分析する研究分野であり、意見マイニングとも呼ばれる (Liu, 2012)。

感情分析は、分析対象の粒度に応じて、文書単位、文単位、アスペクト単位などに分類される (Liu, 2012)。文書単位では、文書全体が肯定的または否定的な意見を表しているかを判定する。文単位では、個々の文が肯定的・否定的・中立的のいずれであるかを判定する。アスペクト単位では、製品やサービスなどの評価対象が持つ特定の属性に対する意見を分析する。本研究では、SNS 投稿に含まれる個別の表現や属性を抽出するのではなく、1 件の投稿全体に対して感情極性ラベルを予測する。そのため、本研究のタスクは、SNS 投稿 1 件を対象とする文書単位の感情分析に位置づけられる。

2.2 WRIME および WRIME Ver.2

WRIME は、日本語 SNS 投稿 17,000 件に対して、書き手本人による主観的な感情強度ラベルと、読み手による客観的な感情強度ラベルを付与したデータセットである。対象となる感情は、喜び、悲しみ、期待、驚き、怒り、恐れ、嫌悪、信頼の 8 種類であり、それぞれの感情強度が 0 から 3 までの 4 段階で付与されている (Kajiwara et al., 2021)。このように、WRIME は書き手自身の感情と、読み手が文章から受け取る感情を区別している点に特徴がある。

WRIME Ver.2 は、WRIME を基礎として、日本語 SNS 投稿 35,000 件に、8 種類の感情強度ラベルと感情極性ラベルを付与したデータセットである。いずれのラベルについても、書き手本人による主観的なラベルと、読み手による客観的なラベルの両方が付与されている。感情極性ラベルは、-2 (強いネガティブ)、-1 (ネガティブ)、0 (中立)、+1 (ポジティブ)、+2 (強いポジティブ) の 5 段階で構成される (Suzuki et al., 2022)。

Suzuki et al. (2022) は、テキストから感情極性ラベル (-2, -1, 0, +1, +2) のいずれかを推定する 5 クラス分類の性能を評価している。本研究では、書き手本人による主観的な感情極性ラベルを予測対象とし、5 クラスの感情極性分類を行う。

2.3 大規模言語モデルを用いた感情分析

大規模言語モデルは、タスクの説明、ラベル集合、および出力形式をプロンプトとして与えることで、対象データによる追加学習を行わないゼロショットで感情分析を実行できる。また、正解ラベルを付した少数の例をプロンプトに含める少数ショットでは、文脈内学習によってタスクへの適応を図ることができる (Zhang et al., 2024)。Zhang et al.

(2024) は、感情分類、アスペクトベース感情分析、および主観的テキストの多面的分析からなる 13 タスク・26 データセットを用い、大規模言語モデルのゼロショットおよび少

数ショット性能を、タスクごとに学習した小規模言語モデルと比較した。

その結果、大規模言語モデルは、単純な感情分類ではゼロショットでも、対象領域の全学習データでファインチューニングした小規模言語モデルに匹敵する場合があった。一方、感情の対象や意見表現などを構造化して出力するアスペクトベース感情分析や、特定の感情現象に対する深い理解を要するタスクでは、全体としてファインチューニングした小規模言語モデルを下回った。また、ChatGPT を用いた検証では、特に構造化された出力を要するタスクにおいて、プロンプトの設計によって性能が大きく変化した。少数ショット条件では、ChatGPT が同じ少数事例で学習した T5-large をほぼ一貫して上回ったが、ChatGPT に与える例を増やした際の効果はタスクの複雑さによって異なった (Zhang et al., 2024)。

この知見は、大規模言語モデルによる感情分析の性能が、使用するモデルの特性、タスクの粒度や複雑さ、出力形式、プロンプト、および学習条件によって異なることを示している。ただし、Zhang et al. (2024) が大規模言語モデルとして評価したモデルは、本研究で用いる Gemma 3 270M とは系列および規模が異なり、評価に用いたデータセットもすべて英語である。したがって、先行研究で得られた知見が、小規模モデルを用いた日本語 SNS 投稿の 5 段階感情極性分類にも当てはまるかは明らかでない。

2.4 LoRA によるファインチューニング

フルファインチューニングでは、事前学習済みモデルの全パラメータを更新するため、モデルの大規模化に伴って学習時の計算資源や、タスクごとに保存するパラメータ量が増大する。これに対して、LoRA は、事前学習済みモデル本体の重みを固定し、Transformer の線形層に低ランク行列を追加して、その低ランク行列を学習対象とするパラメータ効率の高いファインチューニング手法である (Hu et al., 2022)。

LoRA では、ファインチューニングによる重みの更新量 ΔW を、二つの低ランク行列の積として次式のように表現する (Hu et al., 2022)。

$$\Delta W = BA \tag{1}$$

ここで、 A および B は学習対象となる低ランク行列である。元の重み行列を直接更新せず、これらの低ランク行列のみを学習するため、フルファインチューニングと比較して学習可能パラメータ数を削減できる。また、学習後には更新量を元の重みに統合できるため、推論時に追加の計算経路を必要としない。

Hu et al. (2022) は、RoBERTa, DeBERTa, GPT-2, および GPT-3 を対象とした実験において、LoRA が学習可能パラメータ数を削減しながら、フルファインチューニングと同等以上の性能を示し得ることを報告した。日本語の大規模基盤モデルを対象とした王・中町・佐藤 (2023) も、要約、含意関係認識、および常識推論の各タスクで LoRA と

フルファインチューニングを比較した。特に 6.7B モデルでは、LoRA が計算時間と GPU メモリ使用量を削減しつつ、三つのタスクでフルファインチューニングと同等以上の性能を示した。ただし、LoRA によって得られる性能と学習コストは、対象モデル、タスク、適用する層、およびランクなどの設定に依存する (Hu et al., 2022; 王・中町・佐藤, 2023)。

以上より、LoRA は、フルファインチューニングよりも学習コストを抑えてモデルを対象タスクへ適応させる手法として位置づけられる。ただし、先行研究で扱われたモデルやタスクは本研究とは異なり、日本語 SNS 投稿の 5 クラス感情極性分類における有効性は明らかでない。そこで本研究では、Gemma 3 270M を用い、ゼロショット、LoRA ファインチューニング、およびフルファインチューニングについて、同一のデータセット、予測対象、および評価指標を用いて、分類性能と学習コストを比較する。

3. 実験方法

3.1 タスク設定

本研究では、日本語 SNS 投稿から書き手本人の感情極性を予測する 5 クラス分類を扱う。ラベルは-2 (強いネガティブ), -1 (ネガティブ), 0 (中立), +1 (ポジティブ), +2 (強いポジティブ) であり、順序関係を保持したまま評価する (Suzuki et al., 2022)。モデル内部では各ラベルをクラス ID 0 から 4 へ対応させ、評価時に元の数値へ戻す。

三手法では、同じ Gemma 3 モデルを用い、同一の予測対象、テストデータ、評価指標で比較する。ただし、ゼロショットはラベル文字列を生成するのに対し、LoRA およびフルファインチューニングは 5 クラスの分類ヘッドから予測する。

3.2 使用データセット

WRIME Ver.2 は、35,000 件の日本語 SNS 投稿に書き手と読み手の感情ラベルを付与したデータセットである (Suzuki et al., 2022)。本研究では、Hugging Face Datasets の `load_dataset` 関数を用いて、`shunk031/wrime` の `ver2` を取得する。各投稿の本文をモデルへの入力とし、書き手本人が付けた 5 段階の感情極性を正解ラベルとする。データセットに含まれる読み手のラベルと 8 種類の感情強度ラベルは使用しない。

公式分割に従い、学習 30,000 件、検証 2,500 件、テスト 2,500 件を用いる。各分割間で書き手は重複しない。学習データは、LoRA およびフルファインチューニングのパラメータ更新に用いる。検証データでは、各エポック終了時に保存したチェックポイントの QWK を算出し、最も高いチェックポイントを選ぶ。選択したチェックポイントを用いて、テストデータで最終的な分類性能を評価する。ゼロショットには学習・検証データを与えない。

3.3 使用モデル

本研究では、Google の指示調整済みモデル Gemma 3 270M を使用する。Hugging Face 上のモデル識別子は `google/gemma-3-270m-it` である。同モデルは約 2 億 7,000 万パラメータの軽量モデルであり、タスク固有のファインチューニングを想定して設計されている (Lacombe et al., 2025)。限られた計算資源でも、ゼロショット、LoRA、フルファインチューニングを同じモデルで比較できるため採用した。

ゼロショットでは、モデルに感情極性ラベルを文字列として出力させる。LoRA およびフルファインチューニングでは 5 クラスの分類ヘッドを追加し、同じ初期モデルからそれぞれ独立に学習する。

3.4 比較手法

三手法には同じ Gemma 3 モデルを用いる。テストデータは最終評価にのみ使用し、そ

の正解ラベルをプロンプトや学習条件の設定に用いない。また、ゼロショットでは検証データの正解ラベルも使用しない。

ゼロショットでは、学習例を含まない次のプロンプトを用いる。プロンプト中の「{投稿本文}」は各投稿の本文に置き換える。

表 1 ゼロショット推論に用いるプロンプト

次の SNS 投稿に表れている、書き手本人の感情極性を分類してください。 ラベルは、-2 (強いネガティブ)、-1 (ネガティブ)、0 (中立)、+1 (ポジティブ)、+2 (強いポジティブ) の 5 段階です。 回答は「-2」「-1」「0」「+1」「+2」のいずれか一つだけを出力してください。 SNS 投稿：{投稿本文} 回答：
--

LoRA ではモデル本体を固定し、LoRA パラメータと分類ヘッドを学習する。学習後は更新量をモデル本体へ統合する。フルファインチューニングでは、全パラメータと分類ヘッドを学習する。また主な学習条件を表 2 に示す。

表 2 ファインチューニングの学習条件

設定項目	LoRA ファインチューニング	フルファインチューニング
学習対象	LoRA パラメータと分類ヘッド	全パラメータと分類ヘッド
エポック数	3	3
バッチサイズ	32	32
学習率	2×10^{-4}	2×10^{-5}
最大入力長	512	512
演算精度	FP16	FP16
乱数シード	42	42
LoRA ランク	8	該当なし
LoRA スケーリング係数	32	該当なし
LoRA ドロップアウト率	0.1	該当なし

3.5 評価指標

分類性能の主指標には QWK、補助指標には Accuracy と MAE を用いる。QWK は偶然の一致とラベル間の距離を考慮した一致度、Accuracy は正解した事例の割合、MAE は正解ラベルと予測ラベルの平均距離を表す。QWK と Accuracy は値が高いほど、MAE は値が低いほど分類性能が高い。

学習コストは、更新対象パラメータ数、検証を含む 3 エポックの総学習時間、学習時の最大 GPU メモリ使用量で評価する。総学習時間にはデータ取得、前処理、チェックポイントの保存時間を含めない。ゼロショットは追加学習を行わないため、更新対象パラメータ数と学習時間を 0、学習時の最大 GPU メモリ使用量を該当なしとする。

3.6 実験環境

実験は Google Colaboratory 上で行い、NVIDIA T4 GPU を 1 基使用する。実装には Python と PyTorch を用いる。モデルとトークナイザの読み込み、学習、推論には Transformers、データセットの取得と前処理には Datasets、LoRA の適用には PEFT、評価指標の算出には scikit-learn を使用する。

文献リスト

- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., ... Amodei, D. (2020). Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems*, **33**, 1877-1901.
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., ... Chen, W. (2022). LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations*.
- Kajiwara, T., Chu, C., Takemura, N., Nakashima, Y., & Nagahara, H. (2021). WRIME: A New Dataset for Emotional Intensity Estimation with Subjective and Objective Annotations. *Proceedings of NAACL-HLT 2021*, 2095-2104.
- Lacombe, O., Kenealy, K., Black, K., Kumar, R., Visin, F., & Zhang, J. “Gemma 3 270M の概要: 超高効率 AI のためのコンパクトモデル”. Google for Developers. 2025 年 8 月 14 日 . <https://developers.googleblog.com/ja/introducing-gemma-3-270m/>, (2025 年 10 月 20 日)
- Liu, B. (2012). *Sentiment analysis and opinion mining*. San Rafael, CA: Morgan & Claypool Publishers.
- 助田 一晟・鈴木 雅弘・坂地 泰紀・小寺 聡 (2024). JMedLoRA : Instruction-tuning による日本語大規模モデルの医療ドメイン適用 言語処理学会第 30 回年次大会発表論文集, 2548-2553.
- Suzuki, H., Miyauchi, Y., Akiyama, K., Kajiwara, T., Ninomiya, T., Takemura, N., Nakashima, Y., & Nagahara, H. (2022). A Japanese Dataset for Subjective and Objective Sentiment Polarity Classification in Micro Blog Domain. *Proceedings of LREC 2022*, 7022-7028.
- 王 昊・中町 礼文・佐藤 敏紀 (2023). 日本語の大規模な基盤モデル に対する LoRA チューニング 言語処理学会第 29 回年次大会発表論 文集, 2222-2226.
- 山田育矢(2023). 大規模言語モデル入門, 技術評論社
- Zhang, W., Deng, Y., Liu, B., Pan, S. J., & Bing, L. (2024). Sentiment Analysis in the Era of Large Language Models : A Reality Check. *FindingComputational Linguistics: NAACL 2024*, 3881-3906.

生成 AI 活用報告

ChatGPT-5.6 を使い、自分で書いた文章のレビューや構成案の作成を行いました。内容を確認して修正し、もう一度レビューする作業を繰り返しました。また、参考文献の要約や英語部分の翻訳にも使用しました。